beweis beispiel definition satz

1 Foundations of Reinforcement Learning

Wir folgen der Notation aus [1].

Definition 1.1 *Wir definieren für den Markov decision process (MDP) mit Zustandsraum $\mathcal{S}$, Aktionsraum $\mathcal{A}$, Übergangswahrscheinlichkeiten $P : \mathcal{S} \times \mathcal{A} \times \mathcal{S} \to [0, 1]$, Belohnungsfunktion $R : \mathcal{S} \times \mathcal{A} \times \mathcal{S} \to \mathbb{R}$ und Diskontfaktor $\gamma \in [0, 1)$ die optimale Value-Funktion als*

Definition 1.2 (Value-Funktion) *Wir definieren die Value-Funktion für eine Policy π als*

$$V^\pi(\boldsymbol{s}) = \mathsf{E}\left[\sum_{i=0}^{\infty} \gamma^i \cdot r_{t+i+1} \mid \boldsymbol{s}_t = \boldsymbol{s}\right]$$

$$\begin{aligned}
V^\pi(\boldsymbol{s}) &= \mathsf{E}\left[\sum_{i=0}^{\infty} \gamma^i \cdot r_{t+i+1} \mid \boldsymbol{s}_t = \boldsymbol{s}\right] \\
&= \mathsf{E}\left[r_{t+1} \mid \boldsymbol{s}_t = \boldsymbol{s}\right] + \gamma \cdot \mathsf{E}\left[\sum_{i=0}^{\infty} \gamma^i \cdot r_{t+i+2} \mid \boldsymbol{s}_t = \boldsymbol{s}\right] \\
&= \mathsf{E}\left[r_{t+1} \mid \boldsymbol{s}_t = \boldsymbol{s}\right] + \gamma \cdot \mathsf{E}\left[\underbrace{\mathsf{E}\left[\sum_{i=0}^{\infty} \gamma^i \cdot r_{t+i+2} \mid \boldsymbol{s}_{t+1}\right]}_{V^\pi(\boldsymbol{s}_{t+1})} \mid \boldsymbol{s}_t = \boldsymbol{s}\right] \\
\Rightarrow V^\pi(\boldsymbol{s}) &= \mathsf{E}\left[r_{t+1} + \gamma \cdot V^\pi(\boldsymbol{s}_{t+1}) \mid \boldsymbol{s}_t = \boldsymbol{s}\right]
\end{aligned}$$

Denn es gilt hier für die σ-Algebren, dass $\sigma(\boldsymbol{s}_t) \subseteq \sigma(\boldsymbol{s}_{t+1})$ gilt. Explizit ausgeschrieben in Erwartungswerten ergibt sich:

$$\begin{aligned}
V^\pi(\boldsymbol{s}) &= \mathsf{E}\left[r_{t+1} + \gamma V^\pi(\boldsymbol{s}_{t+1}) \mid \boldsymbol{s}_t = \boldsymbol{s}\right] \\
&= \mathsf{E}_{a_t \sim \pi(\cdot|\boldsymbol{s})}\left[\mathsf{E}\left[r_{t+1} + \gamma V^\pi(\boldsymbol{s}_{t+1}) \mid \boldsymbol{s}_t = \boldsymbol{s}, a_t = a\right]\right] \\
&= \mathsf{E}_{a_t \sim \pi(\cdot|\boldsymbol{s})}\left[\mathsf{E}_{\boldsymbol{s}_{t+1} \sim T_a(\boldsymbol{s})}\left[R_{a_t}(\boldsymbol{s}_t, \boldsymbol{s}_{t+1}) + \gamma V^\pi(\boldsymbol{s}_{t+1})\right]\right] \\
&= \mathsf{E}_{a \sim \pi(\cdot|\boldsymbol{s})}\left[\mathsf{E}_{\boldsymbol{s}' \sim T_a(\boldsymbol{s})}\left[R_a(\boldsymbol{s}, \boldsymbol{s}') + \gamma V^\pi(\boldsymbol{s}')\right]\right]
\end{aligned}$$

Definition 1.3 (Q-Function) *Wir definieren die Q-Function als*

$$Q^\pi(\boldsymbol{s}, a) = \mathsf{E}\left[\sum_{i=0}^{\infty} \gamma^i \cdot r_{t+i+1} \mid \boldsymbol{s}_t = \boldsymbol{s}, a_t = a\right] \Rightarrow V^\pi(\boldsymbol{s}) = \mathsf{E}_{a \sim \pi(\cdot|\boldsymbol{s})}\left[Q^\pi(\boldsymbol{s}, a)\right]$$

Herleitung der Bellmann Gleichung für die Q-Funktion:

$$\begin{aligned}
Q^\pi(\boldsymbol{s}, a) &= \mathsf{E}\left[\sum_{i=0}^{\infty} \gamma^i \cdot r_{t+i+1} \mid \boldsymbol{s}_t = \boldsymbol{s}, a_t = a\right] \\
&= \mathsf{E}\left[\mathsf{E}\left[r_{t+1} + \sum_{i=1}^{\infty} \gamma^i \cdot r_{t+i+1} \mid \boldsymbol{s}_t = \boldsymbol{s}, a_t = a, \boldsymbol{s}_{t+1} = \boldsymbol{s}'\right] \mid \boldsymbol{s}_t = \boldsymbol{s}, a_t = a\right] \\
&= \left[\qquad\qquad \frac{1}{\qquad}\right]
\end{aligned}$$

1.1 Bellman Optimality Equations

Satz 1.4 (Optimality Equation für V) *Die optimale Value-Funktion $V^*(\boldsymbol{s})$ erfüllt:*

$$V^*(\boldsymbol{s}) = \max_a \mathsf{E}_{\boldsymbol{s}' \sim T_a(\boldsymbol{s})} \left[R_a(\boldsymbol{s}, \boldsymbol{s}') + \gamma V^*(\boldsymbol{s}') \right] \quad \pi^*(\boldsymbol{s}) = \arg\max_a \mathsf{E}_{\boldsymbol{s}' \sim T_a(\boldsymbol{s})} \left[R_a(\boldsymbol{s}, \boldsymbol{s}') + \gamma V^*(\boldsymbol{s}') \right]$$

Beweis: Wir setzen $V^*(\boldsymbol{s}) = \max_\pi V^\pi(\boldsymbol{s})$. Für jede Policy π gilt nun $V^*(\boldsymbol{s}') \geq V^\pi(\boldsymbol{s}')$ und somit:

$$V^*(\boldsymbol{s}) = \max_\pi \mathsf{E}_{a \sim \pi(\cdot|\boldsymbol{s})} \left[\mathsf{E}_{\boldsymbol{s}' \sim T_a(\boldsymbol{s})} \left[R_a(\boldsymbol{s}, \boldsymbol{s}') + \gamma V^\pi(\boldsymbol{s}') \right] \right] \leq \max_\pi \mathsf{E}_{a \sim \pi(\cdot|\boldsymbol{s})} \left[\mathsf{E}_{\boldsymbol{s}' \sim T_a(\boldsymbol{s})} \left[R_a(\boldsymbol{s}, \boldsymbol{s}') + \gamma V^*(\boldsymbol{s}') \right] \right]$$

Das Maximum über alle Policies π wird erreicht durch die Policy, die in jedem Zustand $\boldsymbol{s}$ die Aktion a auswählt, die das Maximum in der inneren Erwartung erreicht. Somit gilt:

$$V^*(\boldsymbol{s}) \leq \max_a \mathsf{E}_{\boldsymbol{s}' \sim T_a(\boldsymbol{s})} \left[R_a(\boldsymbol{s}, \boldsymbol{s}') + \gamma V^*(\boldsymbol{s}') \right]$$

Wir konstruieren nun die greedy Policy π^* mittels:

$$\pi^*(\boldsymbol{s}) = \arg\max_a \mathsf{E}_{\boldsymbol{s}' \sim T_a(\boldsymbol{s})} \left[R_a(\boldsymbol{s}, \boldsymbol{s}') + \gamma V^*(\boldsymbol{s}') \right]$$

Für diese Policy π^* gilt nun:

$$V^{\pi^*}(\boldsymbol{s}) = \max_a \mathsf{E}_{\boldsymbol{s}' \sim T_a(\boldsymbol{s})} \left[R_a(\boldsymbol{s}, \boldsymbol{s}') + \gamma V^*(\boldsymbol{s}') \right] \geq V^*(\boldsymbol{s}) \Rightarrow V^{\pi^*}(\boldsymbol{s}) = V^*(\boldsymbol{s})$$

□

Satz 1.5 (Optimality Equation für Q-Funktion) *Die optimale Q-Funktion $Q^*(\boldsymbol{s}, a)$ erfüllt:*

$$Q^*(\boldsymbol{s}, a) = \mathsf{E}_{\boldsymbol{s}' \sim T_a(\boldsymbol{s})} \left[R_a(\boldsymbol{s}, \boldsymbol{s}') + \gamma \max_{a'} Q^*(\boldsymbol{s}', a') \right] \quad \pi^*(\boldsymbol{s}) = \arg\max_a Q^*(\boldsymbol{s}, a)$$

Beweis: Für die optimale Q-Funktion gilt somit

$$Q^*(\boldsymbol{s}, a) = \max_\pi Q^\pi(\boldsymbol{s}, a) \Rightarrow Q^*(\boldsymbol{s}, a) = \mathsf{E}_{\boldsymbol{s}' \sim T_a(\boldsymbol{s})} \left[R_a(\boldsymbol{s}, \boldsymbol{s}') + \gamma \max_{a'} Q^*(\boldsymbol{s}', a') \right]$$

Für die optimale Policy gilt:

$$\pi^*(\boldsymbol{s}) = a^* = \arg\max_a Q^*(\boldsymbol{s}, a)$$

□

1.2 Value Iteration

Wir definieren die Abbildung $\mathcal{T}$ als

$$\mathcal{T}[V](\boldsymbol{s}, a) := \max_a \mathsf{E}_{\boldsymbol{s}' \sim T_a(\boldsymbol{s})} \left[R_a(\boldsymbol{s}, \boldsymbol{s}') + \gamma V(\boldsymbol{s}', a') \right]$$

Die Bellmann Optimalitätsgleichung **??** sagt nun aus, dass V^* der Fixpunkt der Abbildung $\mathcal{T}$ ist, also $\mathcal{T}[V^*] = V^*$ gilt. Die Fixpunktiteration $V_{k+1} = \mathcal{T}[V_k]$ konvergiert somit gegen V^*.

Beweis: Wir zeigen zunächst, dass $\mathcal{T}$ eine Kontraktion ist:

$$
\begin{aligned}
|\mathcal{T}[V] - \mathcal{T}[U]| &= \left| \max_a \mathsf{E}_{\boldsymbol{s}' \sim T_a(\boldsymbol{s})} \left[R_a(\boldsymbol{s}, \boldsymbol{s}') + \gamma V(\boldsymbol{s}') \right] - \max_a \mathsf{E}_{\boldsymbol{s}' \sim T_a(\boldsymbol{s})} \left[R_a(\boldsymbol{s}, \boldsymbol{s}') + \gamma U(\boldsymbol{s}') \right] \right| \\
&\leq \max_a \left| \mathsf{E}_{\boldsymbol{s}' \sim T_a(\boldsymbol{s})} \left[R_a(\boldsymbol{s}, \boldsymbol{s}') + \gamma V(\boldsymbol{s}') \right] - \mathsf{E}_{\boldsymbol{s}' \sim T_a(\boldsymbol{s})} \left[R_a(\boldsymbol{s}, \boldsymbol{s}') + \gamma U(\boldsymbol{s}') \right] \right| \\
&= \max_a \left| \mathsf{E}_{\boldsymbol{s}' \sim T_a(\boldsymbol{s})} \left[\gamma (V(\boldsymbol{s}') - U(\boldsymbol{s}')) \right] \right| \\
&\leq \max_a \mathsf{E}_{\boldsymbol{s}' \sim T_a(\boldsymbol{s})} \left[\gamma \cdot \underbrace{\sup_{\boldsymbol{s}'} |V(\boldsymbol{s}') - U(\boldsymbol{s}')|}_{\|V-U\|_\infty} \right] \\
&= \gamma \|V - U\|_\infty
\end{aligned}
$$

Nach dem Fixpunktsatz von Banach [2] konvergiert die Iteration $V_{k+1} = \mathcal{T}(V_k)$ gegen V^* für $k \to \infty$. □

Algorithm 1 Value Iteration

Initialize $V_0(s)$ arbitrarily for all $s \in \mathcal{S}$
$k \leftarrow 0$
repeat
  for each $s \in \mathcal{S}$ **do**
    $V_{k+1}(s) \leftarrow \max_a \underbrace{\mathsf{E}_{s' \sim T_a(s)} \left[R_a(s, s') + \gamma V_k(s') \right]}_{Q_k(s,a)} = \max_a \sum_{s'} T_a(s, s') \left[R_a(s, s') + \gamma V_k(s') \right]$
  end for
  $k \leftarrow k + 1$
until $|V_k - V_{k-1}| < \varepsilon$
return V_k

1.3 Q-Learning

Wir betrachten die Optimalitätsgleichung für die Q-Funktion **??**:

$$Q^*(\boldsymbol{s}, a) = \mathsf{E}_{\boldsymbol{s}' \sim T_a(\boldsymbol{s})} \left[R_a(\boldsymbol{s}, \boldsymbol{s}') + \gamma \max_{a'} Q^*(\boldsymbol{s}', a') \right]$$

und definieren erneut den Operator $\mathcal{T}$ als

$$\mathcal{T}[Q](\boldsymbol{s}, a) := \mathsf{E}_{\boldsymbol{s}' \sim T_a(\boldsymbol{s})} \left[R_a(\boldsymbol{s}, \boldsymbol{s}') + \gamma \max_{a'} Q(\boldsymbol{s}', a') \right]$$

und erhalten erneut die Fixpunktgleichung $\mathcal{T}[Q^*] = Q^*$. Die Fixpunktiteration $Q_{k+1} = \mathcal{T}[Q_k]$ konvergiert somit gegen Q^*, allerdings ist die Berechnung der Erwartungswerte nicht möglich, da wir das Modell $\boldsymbol{s}' = T_a(\boldsymbol{s})$ nicht kennen.

Algorithm 2 Q-Learning

Given Environment, learning rate $\alpha \in (0, 1]$, discount factor $\gamma \in [0, 1)$, exploration rate $\epsilon \in (0, 1)$
Initialize $Q(s, a)$ arbitrarily for all $s \in \mathcal{S}, a \in \mathcal{A}$
$Q(\text{terminal}, \cdot) = 0$ ▷ Terminale Zustände haben Wert 0
for each episode **do**
  Initialize state s
  while state s is not terminal **do**
    Choose action $a = \epsilon$-greedy$(Q[s, \cdot], \epsilon)$ ▷ Exploration vs. Exploitation
    $(s', r) = \mathit{Environment}(s, a)$
    $Q[s, a] \leftarrow (1 - \alpha) \cdot Q[s, a] + \alpha \cdot (r + \gamma \cdot \max_{a'} Q[s', a'])$ ▷ Bootstrapping und TD-Learning
    $s \leftarrow s'$
  end while
end for

Beweis: Wir prüfen die Vorraussetzungen für die Konvergenz von Q-Learning aus [3] und folgern die Konvergenz gegen Q^* fast sicher.

- Der Beweis, dass $\mathcal{T}$ eine Kontraktion ist, verläuft analog zum Beweis für die Value-Funktion.

$$\begin{aligned}
|\mathcal{T}[Q] - \mathcal{T}[U]| &= \left| \mathsf{E}_{\boldsymbol{s}' \sim T_a(\boldsymbol{s})} \left[R_a(\boldsymbol{s}, \boldsymbol{s}') + \gamma \max_{a'} Q(\boldsymbol{s}', a') \right] - \mathsf{E}_{\boldsymbol{s}' \sim T_a(\boldsymbol{s})} \left[R_a(\boldsymbol{s}, \boldsymbol{s}') + \gamma \max_{a'} U(\boldsymbol{s}', a') \right] \right| \\
&= \left| \mathsf{E}_{\boldsymbol{s}' \sim T_a(\boldsymbol{s})} \left[\gamma \left(\max_{a'} Q(\boldsymbol{s}', a') - \max_{a'} U(\boldsymbol{s}', a') \right) \right] \right| \\
&\leq \gamma \mathsf{E}_{\boldsymbol{s}' \sim T_a(\boldsymbol{s})} \left[\gamma \cdot \underbrace{\max_{a'} |Q(\boldsymbol{s}', a') - U(\boldsymbol{s}', a')|}_{\leq \|Q - U\|_\infty} \right] \\
&\leq \gamma \|Q - U\|_\infty
\end{aligned}$$

- Wir verwenden folgende Update-Regel, um die Q-Funktion zu approximieren:

$$
\begin{aligned}
Q_{k+1}(\boldsymbol{s}, a) &= Q_k(\boldsymbol{s}, a) + \alpha \cdot \left[\underbrace{R_a(\boldsymbol{s}, \boldsymbol{s}') + \gamma \cdot \max_{a'} Q_k(\boldsymbol{s}', a')}_{\text{Sample of } T[Q_k]} - Q_k(\boldsymbol{s}, a) \right] \\
&= Q_k(\boldsymbol{s}, a) + \alpha \cdot \left[\mathcal{T}[Q_k](\boldsymbol{s}, a) - Q_k(\boldsymbol{s}, a) + \underbrace{R_a(\boldsymbol{s}, \boldsymbol{s}') + \gamma \cdot \max_{a'} Q_k(\boldsymbol{s}', a') - \mathcal{T}[Q_k](\boldsymbol{s}, a)}_{\eta_k} \right] \\
&= Q_k(\boldsymbol{s}, a) + \alpha \cdot \left[\mathcal{T}[Q_k](\boldsymbol{s}, a) - Q_k(\boldsymbol{s}, a) + \eta_k \right]
\end{aligned}
$$

  Für den Erwartungswert des Rauschterms η_k gilt:

$$
\mathsf{E}_{\boldsymbol{s}' \sim T_a(\boldsymbol{s})} \left[\eta_k \mid Q_k \right] = \mathsf{E}_{\boldsymbol{s}' \sim T_a(\boldsymbol{s})} \left[R_a(\boldsymbol{s}, \boldsymbol{s}') + \gamma \cdot \max_{a'} Q_k(\boldsymbol{s}', a') - \underbrace{\mathcal{T}[Q_k](\boldsymbol{s}, a)}_{\text{deterministic}} \mid Q_k \right] = 0
$$

- Wir definieren die ϵ-Greedy-Policy:

$$
\pi_\epsilon(a, \boldsymbol{s}) := \begin{cases} 1 - \epsilon + \frac{\varepsilon}{|\mathcal{A}|} & \text{if } a = \arg\max_{a'} Q[\boldsymbol{s}, a'] \\ \frac{\varepsilon}{|\mathcal{A}|} & \text{else} \end{cases} = (1 - \epsilon) \cdot \mathbb{1}_{a = \arg\max_{a'} Q[\boldsymbol{s}, a']} + \frac{\epsilon}{|A|}
$$

□

Literatur

[1] Aske Plaat. *Deep Reinforcement Learning*. Springer, 2022. ISBN: 978-981-19-0637-4.

[2] Richard S. Sutton und Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, 2018.

[3] John N. Tsitsiklis. "Asynchronous Stochastic Approximation and Q-Learning". In: *Machine Learning* (1992).